

# 64-040 Modul InfB-RS: Rechnerstrukturen

https://tams.informatik.uni-hamburg.de/ lectures/2016ws/vorlesung/rs

- Kapitel 5 -

### Andreas Mäder



Universität Hamburg Fakultät für Mathematik, Informatik und Naturwissenschaften Fachbereich Informatik

Technische Aspekte Multimodaler Systeme

Wintersemester 2016/2017

5 Ziffern und Zahlen

### Ziffern und Zahlen

Konzept der Zahl

Stellenwertsystem

Umrechnung zwischen verschiedenen Basen

Zahlenbereich und Präfixe

Festkommazahlen

Darstellung negativer Zahlen

Gleitkomma und IEEE 754

Maschinenworte

Literatur

5.1 Ziffern und Zahlen - Konzept der Zahl

- Das Messen ist der Ursprung der Zahl
- als Abstraktion der Anzahl von Objekten
- ▶ die man abzählen kann
- Anwendung des Distributivgesetzes
  - 2 Äpfel + 5 Äpfel = 7 Äpfel
  - 2 Birnen + 5 Birnen = 7 Birnen

. . .

$$\Rightarrow$$
 2 + 5 = 7

Ziffern und Zahlen - Konzept der Zahl 64-040 Rechnerstrukturen

- Zahlenbereich: kleinste und größte darstellbare Zahl?
- Darstellung negativer Werte?
- ► –"− gebrochener Werte?
- ► -"- sehr großer Werte?
- Unterstützung von Rechenoperationen?
   Addition, Subtraktion, Multiplikation, Division, etc.
- ► Abgeschlossenheit unter diesen Operationen?
- ▶ Methode zur dauerhaften Speicherung/Archivierung?
- ► Sicherheit gegen Manipulation gespeicherter Werte?

5.1 Ziffern und Zahlen - Konzept der Zahl

64-040 Rechnerstrukturen

# Georges Ifrah Universalgeschichte der Zahlen



# Klassifikation verschiedener Zahlensysteme

5.1 Ziffern und Zahlen - Konzept der Zahl

64-040 Rechnerstrukturen




Abb. 334: Hierarchisierte Klassifizierung der Zahlschriften naci (1975, 36, Tab. 2; überarbeitet durch d. Verf.)

5.1 Ziffern und Zahlen - Konzept der Zahl





Abb. 1: Auf einen Blick können wir mit unserer direkten Zahlenwahrnehmung feststellen, ob eine Gesamtheit ein, zwei, drei oder vier Elemente umfaßt; Mengen, die größer sind, müssen wir meistens »zählen» – oder mit Hilfe des Vergleichs oder der gedanklichen Aufteilung in Teilmengen erfassen –, da unsere direkte Wahrnehmung nicht mehr ausreicht, exakte Angaben zu machen.

# Abstraktion: Verschiedene Symbole für eine Zahl

5.1 Ziffern und Zahlen - Konzept der Zahl

64-040 Rechnerstrukturen

4bb. 11: Verschiedene, einer ganzen Zahl (hier der Zahl 5) zugeordnete Symbole



FIGURLICHE ZAHLZEICHEN

[lfr10]

# Zählen mit den Fingern ("digits")

5.1 Ziffern und Zahlen - Konzept der Zahl

64-040 Rechnerstrukturen

	1	2	3	4	5
A	M	V			
В				M	
С					
D					




Abb. 12: Verschiedene Möglichkeiten des Zählens mit den Fingern.

[lfr10]

5.1 Ziffern und Zahlen - Konzept der Zahl

### Gegenstände, Hammel und Ziegen betreffend

- 21 Mutterschafe
- 6 weibliche Lämmer
- 8 erwachsene Hammel
- 4 männliche Lämmer
- 6 Mutterziegen
- 1 Bock
- (2) Jungziegen

Abb. 3: Eiförmige Tonbörse (46 mm × 62 mm × 50 mm), entdeckt in den Ruinen des Palastes von Nuzi (mesopotamische Stadt; ca. 15. Jh. v. Chr.). (Harvard Semitic Museum, Cambridge. Katalognummer SMN 1854)

48 Tonkügelchen im Inneren: tamper-proof



5.1 Ziffern und Zahlen - Konzept der Zahl





Abb. 58: Kerbhölzer aus Bäckereien in Frankreich, wie sie in kleinen Ortschaften auf dem Lande üblich waren.




Abb. 59: Englische Kerbhölzer aus dem 13. Jahrhundert. (Sammlung Society of Antiquaries, London; Zeichnung nach Menninger 1957/58, II, 42)

[lfr10]





Abb. 66: Interpretation eines quipu: Die Zahl 658 auf der Schnur E ist gleich der Summe der Zahlen auf den Schnüren A, B, C und D. Dieses Bündel ist das erste an einem peruanischen quipu. (American Museum of Natural History, New York, B 8713; vgl. Leland Locke 1923)

[lfr10]

- ► Ziffern: I=1, V=5, X=10, L=50, C=100, D=500, M=1000
- Werte eins bis zehn: I, II, III, IV, V, VI, VII, VIII, IX, X
- Position der Ziffern ist signifikant:
  - ▶ nach Größe der Ziffernsymbole sortiert, größere stehen links
  - ▶ andernfalls Abziehen der kleineren von der größeren Ziffer
  - ► IV=4, VI=6, XL=40, LXX=70, CM=900
- ▶ heute noch in Gebrauch: Jahreszahlen, Seitennummern, usw. Beispiele: MDCCCXIII=1813, MMIX=2009
- keine Symbole zur Darstellung großer Zahlen
- Rechenoperationen so gut wie unmöglich



(d) (d) (t) C X I

Abb. 87: Römischer Handabakus. (Cabinet des Médailles, Bibliothèque Nationale Paris, br. 1925)

A. Mäder 140

5.1 Ziffern und Zahlen - Konzept der Zahl

Dagegen können im Rahmen einer entwickelten Stellenwertschrift nicht nur alle beliebigen Zahlen jeder Größenordnung mit einer beschränkten Anzahl von Ziffern dargestellt werden, sondern mit ihr kann auch sehr einfach gerechnet werden. Und eben deshalb ist unser Ziffernsystem eine der Grundlagen der geistigen Fähigkeiten der modernen Menschen.

Als Beweis dafür führen wir mit römischen Ziffern eine einfache Addition durch:

CCLXVI	266
MDCCCVII	1 807
DCL	650
MLXXX	1 080
MMMDCCCIII	3 803

Ohne Übertragung auf unsere Zahlschrift wäre das sehr schwierig, wenn nicht unmöglich – und dabei handelt es sich doch bloß um eine Addition! Wie verhielte sich das erst bei einer Multiplikation oder gar bei einer Division? Mit diesen Ziffernsystemen kann nicht gerechnet werden, da ihre Grundziffern einen festgelegten Zahlenwert haben. Diese Ziffern sind keine Recheneinheiten, sondern Abkürzungen, mit denen Ergebnisse von Rechnungen festgehalten werden können, die mit Gegenständen auf der Rechentafel, dem Abakus oder dem Kugelbrett bereits gelöst worden waren.

- ▶ Wahl einer geeigneten Zahlenbasis b ("Radix")
  - ▶ 10: Dezimalsystem
  - ▶ 16: Hexadezimalsystem (Sedezimalsystem)
  - 2: Dualsystem
- ▶ Menge der entsprechenden Ziffern  $\{0, 1, ..., b-1\}$
- ▶ inklusive einer besonderen Ziffer für den Wert Null
- ► Auswahl der benötigten Anzahl *n* von Stellen

$$|z| = \sum_{i=0}^{n-1} a_i \cdot b^i$$

b Basis a; Koeffizient an Stelle i

universell verwendbar, für beliebig große Zahlen

64-040 Rechnerstrukturen

Abb. 289: Mathematische Tafel aus Uruk; sie wurde bei Schwarzgrabungen gefunden und stammt aus dem 2. oder 3. Jh. v. Chr. Es handelt sich um eines der ältesten bekannten Zeugnisse für die Verwendung der babylonischen Null.

(Musée du Louvre, Taf. AO 6484, Rückseite; Thureau-Dangin 1922, Nr. 33, Taf. 62; 1938, 76-81. Unveröffentl. Kopie d. Verf.)



64-040 Rechnerstrukturen



Abb. 288: Rechentafel aus der Zeit um 1800-1700 v. Chr.: ihr Inhalt belegt, daß die babylonischen Mathematiker zur Zeit der 1. Dynastie bereits den »Satz des Pythagoras« kannten.\* (Columbia University of New York, Tafel Plimpton 322; unveröffentl. Kopie d. Verf.; vgl. Neugebauer/ Sachs 1945, 38-41, Taf. 25)

	Trans	skription		
eile 1	SANSI-IL-TI ŞI-LI-IP-TIM	ÍB-SÁ SAG G-IÚ	ÍB-SÁ ȘI-LI-IP-TIM	MU-BI-IM
3	1 30 K.15	1;59	2,49	KI 1
4	11 68,56, 58, 14, 50,6,15	56 . 7	3,12;1	KI 2
5	1 58 41 , 15 , 33 , 45	1, 16 , 41	1 . 50 . 49	KI 3
6	1 53 10 7,29 , 32 , 52 , 16	3,31,49	5, 9, 1	Kl 4
7	1,48,54, 1,40	1,5	1;37	/KI III
8	1,47, 6,41,40	5 . 19	8 .1	" KN // W
9	1 43, 11,56 , 28 , 26 , 40	38 . 11	59 ; 1	KI 7
10	1 ,41,33,59, 3,45	13 . 19	20 : 49	KI 8
11	38, 33,36,36	9.1	12 : 49	KI 9
12	1 ,35,10,2,28,27,24,26,40	1 , 22 , 41	2 . 16 . 1	KI 10
13	1 ; 33 , 45	45	1 ,15	KI 11
14		27.59	48 . 49	KI 12
15 (		7 , 12 ; 1	4.49	KI 13
16	1 25 , 48, 51,35 , 6 ,40	29,31	53 , 49	KI A
17	1 23 13 46 4	56	53	KL 235

<sup>\*</sup>Leerstelle, die das Fehlen von Einheiten einer bestimmten Größenordnung bezeichnet.

[lfr10]

64-040 Rechnerstrukturen


- ► Einführung vor ungefähr 4000 Jahren, erstes Stellenwertsystem
- ▶ Basis 60
- ▶ zwei Symbole: | = 1 und < = 10</p>
- ► Einritzen gerader und gewinkelter Striche auf Tontafeln
- ► Null bekannt, aber nicht mitgeschrieben Leerzeichen zwischen zwei Stellen
- Beispiele
  - ► |||||
  - ► <<||| 23
  - ightharpoonup | <<< 90 = 1 · 60 + 3 · 10
  - ightharpoonup | <<|  $3621 = 1 \cdot 3600 + 0 \cdot 60 + 2 \cdot 10 + 1$
- ▶ für Zeitangaben und Winkeleinteilung heute noch in Gebrauch


 $d_n$ 

# Dezimalsystem

5.2 Ziffern und Zahlen - Stellenwertsystem

64-040 Rechnerstrukturen





$$Zahl = \sum_{i = -k}^{n} d_i \times 10^i$$

[TA14]

- ▶ das im Alltag gebräuchliche Zahlensystem
- ► Einer, Zehner, Hunderter, Tausender, usw.
- ► Zehntel, Hundertstel, Tausendstel, usw.

- ► Stellenwertsystem zur Basis 2
- ▶ braucht für gegebene Zahl ca. dreimal mehr Stellen als Basis 10
- für Menschen daher unbequem besser Oktal- oder Hexadezimalschreibweise, s.u.
- technisch besonders leicht zu implementieren weil nur zwei Zustände unterschieden werden müssen
   z.B. zwei Spannungen, Ströme, Beleuchtungsstärken siehe Kapitel 4: Information Binärzeichen
- + robust gegen Rauschen und Störungen
- + einfache und effiziente Realisierung von Arithmetik

# Dualsystem: Potenztabelle

5.2 Ziffern und Zahlen - Stellenwertsystem

64-040 Rechnerstrukturen

Stelle	Wert im Dualsystem	Wert im Dezimalsystem
$2^{0}$	1	1
$2^1$	10	2
$2^{2}$	100	4
$2^{3}$	1000	8
$2^{4}$	1 0000	16
$2^{5}$	10 0000	32
$2^{6}$	100 0000	64
2 <sup>7</sup>	1000 0000	128
28	1 0000 0000	256
2 <sup>9</sup>	10 0000 0000	512
$2^{10}$	100 0000 0000	1024
$2^{11}$	1000 0000 0000	2048
$2^{12}$	1 0000 0000 0000	4096

- 5.2 Ziffern und Zahlen Stellenwertsystem
  - ▶ Basis 2
  - ▶ Zeichensatz ist {0, 1}
  - ► Beispiele:

$$\begin{array}{c} 0_2 = 0_{10} \\ 1_2 = 1_{10} \\ 11_2 = 3_{10} & 2^1 + 2^0 \\ 11\,0100_2 = 52_{10} & 2^5 + 2^4 + 2^2 \\ 1111\,1110_2 = 254_{10} & 2^8 + 2^7 + \dots + 2^2 + 2^1 \end{array}$$

64-040 Rechnerstrukturen

- ▶ funktioniert genau wie im Dezimalsystem
- ► Addition mehrstelliger Zahlen erfolgt stellenweise
- Additionsmatrix:

$$\begin{array}{c|cccc} + & 0 & 1 \\ \hline 0 & 0 & 1 \\ 1 & 1 & 10 \\ \end{array}$$

Beispiel

A. Måder 150

- ▶ funktioniert genau wie im Dezimalsystem
- $ightharpoonup p = a \cdot b$  mit Multiplikator a und Multiplikand b
- ▶ Multiplikation von a mit je einer Stelle des Multiplikanten b
- Addition der Teilterme
- ► Multiplikationsmatrix ist sehr einfach:

×	0	1
0	0	0
1	0	1

# Multiplikation im Dualsystem (cont.)

5.2 Ziffern und Zahlen - Stellenwertsystem

64-040 Rechnerstrukturen

 $= 1001\,0001\,0111$ 

= 0x917

# Beispiel

- ► Basis 8
- ► Zeichensatz ist {0, 1, 2, 3, 4, 5, 6, 7}
- C-Schreibweise mit führender Null als Präfix:

▶ 
$$0001 = 1_{10}$$
  
 $0013 = 11_{10} = 1 \cdot 8 + 3$   
 $0375 = 253_{10} = 3 \cdot 64 + 7 \cdot 8 + 5$   
usw.

- ⇒ Hinweis: also führende Null in C für Dezimalzahlen unmöglich
- ▶ für Menschen leichter lesbar als Dualzahlen
- ► Umwandlung aus/vom Dualsystem durch Zusammenfassen bzw. Ausschreiben von je drei Bits:

$$00 = 000, 01 = 001, 02 = 010, 03 = 011,$$
  
 $04 = 100, 05 = 101, 06 = 110, 07 = 111$ 

- ▶ Basis 16
- ▶ Zeichensatz ist {0, 1, 2, ..., 9, A, B, C, D, E, F}
- ► C-Schreibweise mit Präfix 0x Klein- oder Großbuchstaben

- viel leichter lesbar als entsprechende Dualzahl
- Umwandlung aus/vom Dualsystem durch Zusammenfassen bzw. Ausschreiben von je vier Bits:

```
0x0 = 0000, 0x1 = 0001, 0x2 = 0010, ..., 0x9 = 1001, 0xA = 1010, 0xB = 1011, 0xC = 1100, 0xD = 1101, 0xE = 1110, 0xF = 1111
```

64-040 Rechnerstrukturen

### Binär

Oktal

Dezimal

Hexadezimal

# Umrechnung Dual-/Oktal-/Hexadezimalsystem

5.2 Ziffern und Zahlen - Stellenwertsystem

64-040 Rechnerstrukturen

Beispiele

Hexadezimal
Binär
Oktal

1 9 4 8 B B 6

0 0 0 1 1 0 0 1 0 1 0 0 0 . 1 0 1 1 0 1 1 0 0

0 0 1 4 5 1 0 . 5 5 4

Hexadezimal 7 B A 3 B C 4
Binär 0111101110100011.1011111000100

- ► Gruppieren von jeweils 3 bzw. 4 Bits
- ▶ bei Festkomma vom Dezimalpunkt aus nach außen

# Umrechnung zwischen verschiedenen Basen

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Baser

64-040 Rechnerstrukturen

- Menschen rechnen im Dezimalsystem
- ▶ Winkel- und Zeitangaben auch im Sexagesimalsystem

Basis: 60

- Digitalrechner nutzen (meistens) Dualsystem
- Algorithmen zur Umrechnung notwendig
- Exemplarisch Vorstellung von drei Varianten:
  - 1. vorberechnete Potenztabellen
  - Divisionsrestverfahren
  - Horner-Schema

## Vorgehensweise für Integerzahlen

- 1.a Subtraktion des größten Vielfachen einer Potenz des Zielsystems von der umzuwandelnden Zahl
   gemäß der vorberechneten Potenztabelle
- 1.b Notation dieses größten Vielfachen (im Zielsystem)
- 2.a Subtraktion wiederum des größten Vielfachen vom verbliebenen Rest
- 2.b Addition dieses Vielfachen (im Zielsystem)
  - ▶ Wiederholen der Schritte 2.x, bis Rest = 0

# $Potenztabellen\ Dual/Dezimal$

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

64-040 Rechnerstrukturen

Stelle	Wert	Stelle	Wert im Dualsystem
$2^{0}$	1	10 <sup>0</sup>	1
$2^1$	2	$10^{1}$	1010
$2^{2}$	4	$10^{2}$	110 0100
$2^3$	8	$10^{3}$	11 1110 1000
$2^{4}$	16	10 <sup>4</sup>	10 0111 0001 0000
$2^{5}$	32	$10^{5}$	0x186A0
$2^{6}$	64	$10^{6}$	0xF 42 40
$2^{7}$	128	10 <sup>7</sup>	0×98 96 80
$2^{8}$	256	10 <sup>8</sup>	0x5 F5 E1 00
$2^{9}$	512	10 <sup>9</sup>	0x3B9ACA00
$2^{10}$	1 024	$10^{10}$	0x2 54 0B E4 00
$2^{11}$	2 048	$10^{11}$	0×17 48 76 E8 00
$2^{12}$	4 096	$10^{12}$	0xE8 D4 A5 10 00

. . .

# Potenztabellen: Beispiel

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

▶ Umwandlung Dezimal- in Dualzahl

$$Z = (163)_{10}$$

$$163$$

$$-128$$

$$35$$

$$-32$$

$$3$$

$$-2$$

$$10000000$$

$$3$$

$$-2$$

$$1$$

$$1$$

$$-1$$

$$0$$

$$2^{0}$$

$$+1$$

$$10100011$$

$$Z = (163)_{10} \leftrightarrow (10100011)_{2}$$

Umwandlung Dual- in Dezimalzahl

- Division der umzuwandelnden Zahl im Ausgangssystem durch die Basis des Zielsystems
- Erneute Division des ganzzahligen Ergebnisses (ohne Rest) durch die Basis des Zielsystems, bis kein ganzzahliger Divisionsrest mehr bleibt

```
▶ Beispiel 163: 2 = 81 Rest 1 2^0

81: 2 = 40 Rest 1 : 40: 2 = 20 Rest 0 20: 2 = 10 Rest 0 10: 2 = 5 Rest 0 5: 2 = 2 Rest 1 ↑ Leserichtung 2: 2 = 1 Rest 0 : 1: 2 = 0 Rest 1 2^7 (163)_{10} \leftrightarrow (1010\,0011)_2
```

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Baser

► Umwandlung Dual- in Dezimalzahl

 $Z = (1010\,0011)_2$ 

Hinweis: Division in Basis b folgt

```
Z = (1492)_{10}
                      20
 1492:2=746 Rest 0
  746:2=373 Rest 0
  373 : 2 = 186 Rest 1
  186:2 = 93 Rest 0
   93:2 = 46 Rest 1
   46:2=23 Rest 0
   23:2=11 Rest 1
   11:2=5 Rest 1
    5:2=2 Rest 1
                       ↑ Leserichtung
    2:2=1 Rest 0
                      2^{10}
    1:2 = 0 Rest 1
Z = (1492)_{10} \leftrightarrow (10111010100)_2
```

## Divisionsrestverfahren: Algorithmus

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

64-040 Rechnerstrukturen

## Algorithmus

rechentechnisch

#### darzustellende Zahl x

.23

Basis q

n = 1 a := xwhile a > 0  $y_n := a \mod q$   $a := a \operatorname{div} q$ end  $a := a \operatorname{div} q$   $a := a \operatorname{div} q$ 

K. von der Heide [Hei05] Interaktives Skript T1 stellen2stellen

 Darstellung einer Potenzsumme durch ineinander verschachtelte Faktoren

$$|z| = \sum_{i=0}^{n-1} a_i \cdot b^i = (\dots((a_{n-1} \cdot b + a_{n-2}) \cdot b + a_{n-3}) \cdot b + \dots + a_1) \cdot b + a_0$$

### Vorgehensweise:

- ▶ Darstellung der umzuwandelnden Zahl im Horner-Schema
- Durchführung der auftretenden Multiplikationen und Additionen im Zielsystem

64-040 Rechnerstrukturen

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Baser

- Umwandlung Dezimal- in Dualzahl
  - 1. Darstellung als Potenzsumme  $Z = (163)_{10} = (1 \times 10 + 6) \times 10 + 3$
  - 2. Faktoren und Summanden im Zielzahlensystem  $(10)_{10} \leftrightarrow (1010)_2$

$$\begin{array}{ccc} (6)_{10} \leftrightarrow & (110)_2 \\ (3)_{10} \leftrightarrow & (11)_2 \end{array}$$

$$(1)_{10} \leftrightarrow \qquad (1)_2$$

3. Arithmetische Operationen

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

64-040 Rechnerstrukturen

- Umwandlung Dual- in Dezimalzahl
  - 1. Darstellung als Potenzsumme

$$Z = (10100011)_2 = ((((((1\times10_2+0)\times10_2+1)\times10_2+0)\times10_2+0)\times10_2+0)\times10_2+1)\times10_2+1)$$

2. Faktoren und Summanden im Zielzahlensystem

$$(10)_2 \leftrightarrow (2)_{10}$$

$$(1)_2 \leftrightarrow (1)_{10}$$

$$(0)_2 \leftrightarrow (0)_{10}$$

### 3. Arithmetische Operationen

$$1 \times 2 = 2$$

$$\frac{+0}{2} \times 2 = 4$$

$$\frac{+1}{5} \times 2 = 10$$

$$\frac{+0}{10} \times 2 = 20$$

$$\frac{+0}{20} \times 2 = 40$$

$$\frac{+0}{40} \times 2 = 80$$

$$\frac{+1}{81} \times 2 = 162$$

$$\frac{+1}{163}$$

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

64-040 Rechnerstrukturen

► Umwandlung Dual- in Dezimalzahl  $Z = (1011\ 1011\ 0111)_2 = (2\ 999)_{10}$ 



Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$ 

64-040 Rechnerstrukturen

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0+2\times 23=46$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$  $1 + 2 \times 93 = 187$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$  $1 + 2 \times 93 = 187$  $0+2\times 187=374$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$  $1 + 2 \times 93 = 187$  $0+2\times 187=374$  $1+2\times 374=749$ 

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$  $1 + 2 \times 93 = 187$  $0 + 2 \times 187 = 374$  $1 + 2 \times 374 = 749$  $1+2\times 749=1499$ 

5.3 Ziffern und Zahlen - Umrechnung zwischen verschiedenen Basen

Umwandlung Dual- in Dezimalzahl  $Z = (101110110111)_2 = (2999)_{10}$ 101110110111  $1 + 2 \times 0 = 1$  $0 + 2 \times 1 = 2$  $1 + 2 \times 2 = 5$  $1 + 2 \times 5 = 11$  $1 + 2 \times 11 = 23$  $0 + 2 \times 23 = 46$  $1 + 2 \times 46 = 93$  $1 + 2 \times 93 = 187$  $0 + 2 \times 187 = 374$  $1 + 2 \times 374 = 749$  $1 + 2 \times 749 = 1499$  $1+2\times1499=2999$ 

## Zahlenbereich bei fester Wortlänge

5.4 Ziffern und Zahlen - Zahlenbereich und Präfixe

64-040 Rechnerstrukturen

Anzahl der Bits	Zahl	enbere	ich jeweils von 0 bis $(2^n - 1)$
4-bit	$2^{4}$	=	16
8-bit	2 <sup>8</sup>	=	256
10-bit	$2^{10}$	=	1 024
12-bit	$2^{12}$	=	4 096
16-bit	$2^{16}$	=	65 536
20-bit	$2^{20}$	=	1 048 576
24-bit	$2^{24}$	=	16 777 216
32-bit	$2^{32}$	=	4 294 967 296
48-bit	$2^{48}$	=	281 474 976 710 656
64-bit	$2^{64}$	=	18 446 744 073 709 551 616

Für die vereinfachte Schreibweise von großen bzw. sehr kleinen Werten ist die Präfixangabe als Abkürzung von Zehnerpotenzen üblich. Beispiele:

- ► Lichtgeschwindigkeit: 300 000 Km/s = 30 cm/ns
- ▶ Ruheenergie des Elektrons: 0,51 MeV
- ► Strukturbreite heutiger Mikrochips: 14 nm
- usw.

Es gibt entsprechende Präfixe auch für das Dualsystem. Dazu werden Vielfache von  $2^{10}=1024\approx 1000$  verwendet.

# Präfixe für Einheiten im Dezimalsystem

5.4 Ziffern und Zahlen - Zahlenbereich und Präfixe

64-040 Rechnerstrukturen

Faktor	Name	Symbol	Faktor	Name	Symbol
$10^{24}$	yotta	Υ	$10^{-24}$	yocto	У
$10^{21}$	zetta	Z	$10^{-21}$	zepto	Z
$10^{18}$	exa	E	$10^{-18}$	atto	а
$10^{15}$	peta	Р	$10^{-15}$	femto	f
$10^{12}$	tera	Т	$10^{-12}$	pico	р
$10^{9}$	giga	G	$10^{-9}$	nano	n
$10^{6}$	mega	М	$10^{-6}$	micro	$\mu$
$10^{3}$	kilo	K	$10^{-3}$	milli	m
$10^{2}$	hecto	h	$10^{-2}$	centi	С
$10^{1}$	deka	da	$10^{-1}$	dezi	d

5.4 Ziffern und Zahlen - Zahlenbereich und Präfixe

64-040 Rechnerstrukturen

Faktor	Name	Symbol	Langname
$2^{60}$	exbi	Ei	exabinary
$2^{50}$	pebi	Pi	petabinary
$2^{40}$	tebi	Ti	terabinary
$2^{30}$	gibi	Gi	gigabinary
$2^{20}$	mebi	Mi	megabinary
$2^{10}$	kibi	Ki	kilobinary

Beispiele: 1 kilobit = 1024 bit 1 kilobit = 1000 bit 1 megibit = 1048576 bit1 gibibit = 1073741824 bit

IEC-60027-2, Letter symbols to be used in electrical technology

In der Praxis werden die offiziellen Präfixe nicht immer sauber verwendet. Meistens ergibt sich die Bedeutung aber aus dem Kontext. Bei Speicherbausteinen sind Zweierpotenzen üblich, bei Festplatten dagegen die dezimale Angabe.

- ▶ DRAM-Modul mit 1 GB Kapazität: gemeint sind 2<sup>30</sup> Bytes
- ► Flash-Speicherkarte 4 GB Kapazität: gemeint sind 2<sup>32</sup> Bytes
- ► Festplatte mit Angabe 1 TB Kapazität: typisch 10<sup>12</sup> Bytes
- die tatsächliche angezeigte verfügbare Kapazität ist oft geringer, weil das jeweilige Dateisystem Platz für seine eigenen Verwaltungsinformationen belegt.

Darstellung von **gebrochenen Zahlen** als Erweiterung des Stellenwertsystems durch Erweiterung des Laufindex zu negativen Werten:

$$|z| = \sum_{i=0}^{n-1} a_i \cdot b^i + \sum_{i=-\infty}^{i=-1} a_i \cdot b^i$$
$$= \sum_{i=-\infty}^{n-1} a_i \cdot b^i$$

mit  $a_i \in N$  und  $0 \le a_i \le b$ .

► Der erste Summand bezeichnet den ganzzahligen Anteil, während der zweite Summand für den gebrochenen Anteil steht.

### Nachkommastellen im Dualsystem

5.5 Ziffern und Zahlen - Festkommazahlen

64-040 Rechnerstrukturen

alle Dualbrüche sind im Dezimalsystem exakt darstellbar (d.h. mit endlicher Wortlänge)

▶ dies gilt umgekehrt nicht

64-040 Rechnerstrukturen

5.5 Ziffern und Zahlen - Festkommazahler

- gebrochene Zahlen können je nach Wahl der Basis evtl. nur als unendliche periodische Brüche dargestellt werden
- insbesondere erfordern viele endliche Dezimalbrüche im Dualsystem unendliche periodische Brüche
- ▶ Beispiel: Dezimalbrüche, eine Nachkommastelle

B=10	B=2	B=2	B=10
0,1	$0,0\overline{0011}$	0,001	0,125
0,2	0, $\overline{0011}$	0,010	0,25
0,3	$0,0\overline{1001}$	0,011	0,375
0,4	0, 0110	0,100	0,5
0,5	0, 1	0,101	0,625
0,6	0, 1001	0,110	0,75
0,7	$0, 1\overline{0110}$	0,111	0,875
0,8	0, $\overline{1100}$		
0,9	$0, 1\overline{1100}$	W .0.	

### Potenztabelle zur Umrechnung

Potenztabelle  $2^{-1} = 0.5$   $2^{-7} = 0.0078125$   $2^{-8} = 0.00390625$   $2^{-3} = 0.125$   $2^{-9} = 0.001953125$   $2^{-4} = 0.0625$   $2^{-5} = 0.03125$   $2^{-10} = 0.0009765625$   $2^{-6} = 0.015625$   $2^{-12} = 0.000244140625$ 

Beispiel: Dezimal 0,3
 Berechnung durch Subtraktion der Werte

$$\begin{array}{l} (0,3)_{10} = 0 \cdot 2^{-1} + 1 \cdot 2^{-2} + 0 \cdot 2^{-3} + 0 \cdot 2^{-4} + 1 \cdot 2^{-5} + 1 \cdot 2^{-6} + \dots \\ = 2^{-2} + 2^{-5} + 2^{-6} + 2^{-9} + \dots \\ = (0,0\overline{1001})_2 \end{array}$$

5.5 Ziffern und Zahlen - Festkommazahlen

64-040 Rechnerstrukturen

#### Divisionsrestverfahren

- lue statt Division: bei Nachkommastellen Multiplikation imes 2
  - ▶ man nimmt den Dezimalbruch immer mit 2 mal
  - ► Resultat < 1: eine 0 an den Dualbruch anfügen
    -"- > 1: eine 1 -"-

und den ganzzahligen Anteil streichen: 
$$-1,0$$

- Ende, wenn Ergebnis 1,0 (wird zu 0)
   -"- wenn Rest sich wiederholt ⇒ Periode
- ▶ Beispiel: Dezimal 0,59375

64-040 Rechnerstrukturen

5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

### Drei gängige Varianten zur Darstellung negativer Zahlen

- 1. Betrag und Vorzeichen
- 2. Exzess-Codierung (Offset-basiert)
- 3. Komplementdarstellung
- ▶ Integerrechnung häufig im Zweierkomplement
- ► Gleitkommadarstellung mit Betrag und Vorzeichen
- ► –"− Exponent als Exzess-Codierung

- Auswahl eines Bits als Vorzeichenbit
- meistens das MSB (engl. most significant bit)
- restliche Bits als Dualzahl interpretiert
- Beispiel für 4-bit Wortbreite:

0000	+0		1000	-0
0001	+1		1001	-1
0010	+2		1010	-2
0011	+3		1011	-3
0100	+4		1100	-4
0101	+5		1101	-5
0110	+6		1110	-6
0111	+7		1111	-7

- doppelte Codierung der Null: +0, -0
- Rechenwerke für Addition/Subtraktion aufwändig

einfache Um-Interpretation der Binärcodierung

$$z = Z - offset$$

- ▶ mit z vorzeichenbehafteter Wert, Z binäre Ganzzahl,
- ► beliebig gewählter Offset
- Null wird also nicht mehr durch 000...0 dargestellt
- + Größenvergleich zweier Zahlen bleibt einfach
- ▶ Anwendung: Exponenten im IEEE 754 Gleitkommaformat
- und für einige Audioformate

### Exzess-Codierung: Beispiele

5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

64-040 Rechnerstrukturen

Bitmuster	Binärcode	Exzess-8	Exzess-6	(z = Z - offset)
0000	0	-8	-6	
0001	1	-7	-5	
0010	2	-6	-4	
0011	3	-5	-3	
0100	4	-4	-2	
0101	5	-3	-1	
0110	6	-2	0	
0111	7	-1	1	
1000	8	0	2	
1001	9	1//	3	
1010	10	2	4	
1011	11	3	5	
1100	12	4	6	
1101	13	5	7	
1110	14	6	8	
1111	15	7	9	

### Definition: das b-Komplement einer Zahl z ist

$$K_b(z) = b^n - z$$
, für  $z \neq 0$   
= 0, für  $z = 0$ 

- ▶ b: die Basis (des Stellenwertsystems)
- n: Anzahl der zu berücksichtigenden Vorkommastellen
- mit anderen Worten:  $K_b(z) + z = b^n$
- Stellenwertschreibweise

$$z = -a_{n-1} \cdot b^{n-1} + \sum_{i=-m}^{n-2} a_i \cdot b^i$$

► Dualsystem: 2-Komplement

► Dezimalsystem: 10-Komplement

### b-Komplement: Beispiele

5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

64-040 Rechnerstrukturen

$$b = 10 \quad n = 4 \quad K_{10}(3763)_{10} = 10^4 - 3763 = 6237_{10}$$

$$n = 2 \quad K_{10}(0, 3763)_{10} = 10^2 - 0, 3763 = 99, 6237_{10}$$

$$n = 0 \quad K_{10}(0, 3763)_{10} = 10^0 - 0, 3763 = 0, 6237_{10}$$

$$b = 2 \quad n = 2 \quad K_2(10, 01)_2 = 2^2 - 10, 01_2 = 01, 11_2$$

$$n = 8 \quad K_2(10, 01)_2 = 2^8 - 10, 01_2 = 11111101, 11_2$$

Definition: das (b-1)-Komplement einer Zahl z ist

$$K_{b-1}(z) = b^n - b^{-m} - z$$
, für  $z \neq 0$   
= 0, für  $z = 0$ 

- ▶ b: die Basis des Stellenwertsystems
- n: Anzahl der zu berücksichtigenden Vorkommastellen
- ▶ m: Anzahl der Nachkommastellen
- ▶ Dualsystem: 1-Komplement
- ▶ Dezimalsystem: 9-Komplement

▶ Dualsystem: 1-Komplement

1100 1001

$$K_{b-1}(z) = b^n - b^{-m} - z$$
, für  $z \neq 0$ 

- ▶ im Fall m = 0 gilt offenbar  $K_b(z) = K_{b-1}(z) + 1$
- $\Rightarrow$  das (b-1)-Komplement kann sehr einfach berechnet werden: es werden einfach die einzelnen Bits/Ziffern invertiert.

	alle Bits invertieren	0011 0110
► Dezimalsystem:	9-Komplement	24 453
	alle Ziffern invertieren	75 546
	$0 \leftrightarrow 9 \ 1 \leftrightarrow 8 \ 2 \leftrightarrow 7 \ 3 \leftrightarrow 6 \ 4 \leftrightarrow 5$	
	Summe:	99999 = 100000 - 1

⇒ das b-Komplement kann sehr einfach berechnet werden: es werden einfach die einzelnen Bits/Ziffern invertiert und 1 an der niedrigsten Stelle aufaddiert.

5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

64-040 Rechnerstrukturen

 ▶ Dualsystem:
 2-Komplement
 1100 1001

 Bits invertieren +1
 0011 0111

 Summe:
 1 0000 0000

► Dezimalsystem: 10-Komplement 24 453 Ziffern invertieren +1 75 547

 $0 \leftrightarrow 9 \ 1 \leftrightarrow 8 \ 2 \leftrightarrow 7 \ 3 \leftrightarrow 6 \ 4 \leftrightarrow 5$ 

Summe: 100 000

▶ bei Rechnung mit fester Stellenzahl *n* gilt:

$$K_b(z) + z = b^n = 0$$

weil  $b^n$  gerade nicht mehr in n Stellen hineinpasst

▶ also gilt für die Subtraktion auch:

$$x - y = x + K_b(y)$$

- ⇒ Subtraktion kann also durch Addition des b-Komplements ersetzt werden
  - und für Integerzahlen gilt außerdem

$$x - y = x + K_{b-1}(y) + 1$$

# Subtraktion mit Einer- und Zweierkomplement


5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

64-040 Rechnerstrukturen

► Subtraktion ersetzt durch Addition des Komplements

Dezimal	1-Komplement	2-Komplement
10	0000 1010	0000 1010
+(-3)	1111 1100	1111 1101
+7	1 0000 0110	1 0000 0111
Übertrag:	addieren $+1$	verwerfen
	0000 0111	0000 0111

### Beispiel für 4-bit Zahlen



2-Komplement

1-Komplement

- Betrag+Vorzeichen
- ► Komplement-Arithmetik als Winkeladdition (siehe Kapitel 6)
- ► Web-Anwendung: Visualisierung im Zahlenkreis (JavaScript, see: [Kor16])

### Darstellung negativer Zahlen: Beispiele

5.6 Ziffern und Zahlen - Darstellung negativer Zahlen

64-040 Rechnerstrukturen

N	N	-N	-N	-N	-N
Dezimal	Binär	VZ+Betrag	1-Komplement	2-Komplement	Exzess 128
1	0000 0001	1000 0001	1111 1110	1111 1111	0111 1111
2	0000 0010	1000 0010	1111 1101	1111 1110	0111 1110
3	0000 0011	1000 0011	1111 1100	1111 1101	0111 1101
4	0000 0100	1000 0100	1111 1011	1111 1100	0111 1100
5	0000 0101	1000 0101	1111 1010	1111 1011	0111 1011
6	0000 0110	1000 0110	1111 1001	1111 1010	0111 1010
7	0000 0111	1000 0111	1111 1000	1111 1001	0111 1001
8	0000 1000	1000 1000	1111 0111	1111 1000	0111 1000
9	0000 1001	1000 1001	1111 0110	1111 0111	0111 0111
10	0000 1010	1000 1010	1111 0101	1111 0110	0111 0110
20	0001 0100	1001 0100	1110 1011	1110 1100	0110 1100
30	0001 1110	1001 1110	1110 0001	1110 0010	0110 0010
40	0010 1000	1010 1000	1101 0111	1101 1000	0101 1000
50	0011 0010	1011 0010	1100 1101	1100 1110	0100 1110
60	0011 1100	1011 1100	1100 0011	1100 0100	0100 0100
70	0100 0110	1100 0110	1011 1001	1011 1010	0011 1010
80	0101 0000	1101 0000	1010 1111	1011 0000	0011 0000
90	0101 1010	1101 1010	1010 0101	1010 0110	0010 0110
100	0110 0100	1110 0100	1001 1011	1001 1100	00011100
127	0111 1111	1111 1111	1000 0000	1000 0001	0000 0001
128	_	_	_	1000 0000	0000 0000

#### Wie kann man "wissenschaftliche" Zahlen darstellen?

► Masse der Sonne

1,989 · 10<sup>30</sup> Kg

Ladung eines Elektrons

 $0,000\,000\,000\,000\,000\,000\,16\,C$ 

► Anzahl der Atome pro Mol 602 300 000 000 000 000 000 000

. . .

#### Darstellung im Stellenwertsystem?

- gleichzeitig sehr große und sehr kleine Zahlen notwendig
- entsprechend hohe Zahl der Vorkomma- und Nachkommastellen
- durchaus möglich (Java3D: 256-bit Koordinaten)
- ▶ aber normalerweise sehr unpraktisch
- ▶ typische Messwerte haben nur ein paar Stellen Genauigkeit

#### Grundidee: halblogarithmische Darstellung einer Zahl:

- ▶ Vorzeichen (+1 oder -1)
- ► Mantisse als normale Zahl im Stellenwertsystem
- Exponent zur Angabe der Größenordnung

$$z = sign \cdot mantisse \cdot basis^{exponent}$$

- ▶ handliche Wertebereiche für Mantisse und Exponent
- ▶ arithmetische Operationen sind effizient umsetzbar
- Wertebereiche für ausreichende Genauigkeit wählen

Hinweis: rein logarithmische Darstellung wäre auch möglich, aber Addition/Subtraktion sind dann sehr aufwändig.

64-040 Rechnerstrukturen

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

$$z = (-1)^s \cdot m \cdot 10^e$$

- S Vorzeichenbit
- Mantisse als Festkomma-Dezimalzahl
- ▶ e Exponent als ganze Dezimalzahl

► Schreibweise in C/Java: ⟨Vorzeichen⟩ ⟨Mantisse⟩ E ⟨Exponent⟩

6.023E23

 $6,023 \cdot 10^{23}$ 

Avogadro-Zahl

1.6E-19

 $1.6 \cdot 10^{-19}$ 

Elementarladung des Elektrons

# Gleitkomma: Beispiel für Zahlenbereiche

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen

Ste	llen	Zahlenbereich					
Mantisse	Exponent	0 ←	$ ightarrow \infty$				
3	1	$10^{-12}$	10 <sup>9</sup>				
3	2	$10^{-102}$	10 <sup>99</sup>				
3	3	$10^{-1002}$	$10^{999}$				
3	4	$10^{-10002}$	$10^{9999}$				
4	1	$10^{-13}$	$10^{9}$				
4	2	$10^{-103}$	10 <sup>99</sup>				
4	3	$10^{-1003}$	$10^{999}$				
4	4	$10^{-10003}$	10 <sup>9999</sup>				
5	1	$10^{-14}$	10 <sup>9</sup>				
5	2	$10^{-104}$	10 <sup>99</sup>				
5	3	$10^{-1004}$	$10^{999}$				
5	4	$10^{-10004}$	10 <sup>9999</sup>				
10	3	$10^{-1009}$	$10^{999}$				
20	3	$10^{-1019}$	10 <sup>999</sup>				

A. Mäder

197

64-040 Rechnerstrukturen


5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

•	1937	Zuse: Z1 mit 22-bit Gleitkomma-Datenformat						
•	195×	Verbreitung von Gleitkomma-Darstellung für numerische Berechnungen						
<b>•</b>	1980	Intel 8087: erster Koprozessor-Chip, ca. 45 000 Transistoren, ca. 50K FLOPS/s						
•	1985	IEEE 754 Standard für Gleitkomma						
•	1989	Intel 486 mit integriertem Koprozessor						
•	1995	Java-Spezifikation fordert IEEE 754						
•	1996	ASCI-RED: 1 TFLOPS ( 9 152 PentiumPro)						
•	2008	Roadrunner: 1 PFLOPS (12 960 Cell)						

 $\mathsf{FLOPS} := \mathsf{Floating}\text{-}\mathsf{Point}\ \mathsf{Operations}\ \mathsf{Per}\ \mathsf{Second}$ 

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen



- Darstellung üblicherweise als Betrag+Vorzeichen
- negative und positive Zahlen gleichberechtigt (symmetrisch)
- separate Darstellung für den Wert Null
- sieben Zahlenbereiche: siehe Bild
- ► relativer Abstand benachbarter Zahlen bleibt ähnlich (vgl. dagegen Integer: 0/1, 1/2, 2/3, ..., 65 535/65 536, ...)

$$z = (-1)^s \cdot m \cdot 10^e$$

diese Darstellung ist bisher nicht eindeutig:

$$123 \cdot 10^0 = 12, 3 \cdot 10^1 = 1, 23 \cdot 10^2 = 0, 123 \cdot 10^3 = \dots$$

#### normalisierte Darstellung

- ▶ Exponent anpassen, bis Mantisse im Bereich  $1 \le m < b$  liegt
- ⇒ Darstellung ist dann eindeutig
- ⇒ im Dualsystem: erstes Vorkommabit ist dann 1 und muss nicht explizit gespeichert werden
  - evtl. zusätzlich sehr kleine Zahlen nicht-normalisiert

#### bis 1985 ein Wildwuchs von Gleitkomma-Formaten:

- unterschiedliche Anzahl Bits in Mantisse und Exponent
- ► Exponent mit Basis 2, 10, oder 16
- diverse Algorithmen zur Rundung
- ▶ jeder Hersteller mit eigener Variante
- Numerische Algorithmen nicht portabel

#### 1985: Publikation des Standards IEEE 754 zur Vereinheitlichung

- ▶ klare Regeln, auch für Rundungsoperationen
- große Akzeptanz, mittlerweile der universale Standard
- ▶ 2008: IEEE 754-2008 mit 16- und 128-bit Formaten

Details: unter anderem in en.wikipedia.org/wiki/IEEE\_754 oder in Goldberg [Gol91]

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

► 32-bit Format: einfache Genauigkeit (single precision, float)
Bits 1 8 23

V Exponent Mantisse

► 64-bit Format: doppelte Genauigkeit (double precision, double)

Bits 1 11 52

| V | Exponent | Mantisse

- ▶ Mantisse als normalisierte Dualzahl:  $1 \le m < 2$
- ► Exponent in Exzess-127 bzw. Exzess-1023 Codierung
- $\triangleright$  einige Sonderwerte: Null (+0, -0), NaN, Infinity

64-040 Rechnerstrukturen

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

Eigenschaft	einfache	doppelte Genauigkeit			
Bits im Vorzeichen	1	1			
Bits im Exponenten	8	11			
Bits in der Mantisse	23	52			
Bits insgesamt	32	64			
Exponentensystem	Exzess 127	Exzess 1023			
Exponentenbereich	-126+127	-1022+1023			
kleinste normalisierte Zahl	$2^{-126}$	$2^{-1022}$			
größte –"–	$pprox 2^{128}$	$\approx 2^{1024}$			
☐ Dezimalbereich	$pprox 10^{-38} \dots 10^{38}$	$pprox 10^{-308} \dots 10^{308}$			
kleinste nicht normalisierte Zahl	$pprox 10^{-45}$	$pprox 10^{-324}$			

### Matlab-Demo: demoieee754

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen




- ► Zahlenformat wählen (float=short real, double=long real)
- Dezimalzahl in oberes Textfeld eingeben
- ► Mantisse/Exponent/Vorzeichen in unteres Textfeld eingeben
- ► andere Werte werden jeweils aktualisiert

K. von der Heide [Hei05], Interaktives Skript T1, demoieee754

## Matlab-Demo: demoieee754 (cont.)

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen



- ► Genauigkeit bei float: 23+1 bits, ca. 6...7 Dezimalstellen
- ► Genauigkeit bei double: 52+1 bits, ca. 16 Dezimalstellen Erinnerung:  $log_2(10) = ln(10)/ln(2) \approx 3,322$

- ▶ 1-bit Vorzeichen 8-bit Exponent (Exzess-127), 23-bit Mantisse  $z = (-1)^s \cdot 2^{(eeee\ eeee-127)} \cdot 1$ , mmmm mmmm mmmm . . . mmm

$$z = -1 \cdot 2^{(128-127)} \cdot (1+0,5+0,25+0,125+0)$$
  
= -1 \cdot 2 \cdot 1,875 = -3,750

$$z = +1 \cdot 2^{(254-127)} \cdot (1 + 2^{-4} + 2^{-7} + 2^{-8})$$
  
=  $2^{127} \cdot 1,07421875 = 1,953965 \cdot 10^{38}$ 

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

$$z=(-1)^s\cdot 2^{({\sf eeee\ eeee}-127)}\cdot 1$$
, mmmm mmmm mmmm . . . mmm

$$z = -1 \cdot 2^{(1-127)} \cdot (1+0+0+\cdots+0)$$
$$= -1 \cdot 2^{-126} \cdot 1, 0 = -1, 1755 \cdot 10^{-38}$$

$$z = +1 \cdot 2^{(127-127)} \cdot (1 + 2^{-23})$$
$$= 1 \cdot (1 + 0,0000001) = 1,0000001$$

```
public static void main( String[] args ) {
 public void p( String s, String e, String m ) {
 int
         sign = (Integer.parseInt(s, 2) & 0x1) << 31;
 int exponent = (Integer.parseInt( e, 2 ) & 0xFF) << 23;</pre>
 int mantisse = (Integer.parseInt( m, 2 ) & 0x007FFFFF);
 int bits = sign | exponent | mantisse;
 float f = Float.intBitsToFloat( bits );
 System.out.println( dumpIntBits(bits) + " " + f );
public String dumpIntBits( int i ) {
 StringBuffer sb = new StringBuffer();
 for( int mask=0x80000000; mask != 0; mask = mask >>> 1 ) {
   sb.append( ((i & mask) != 0) ? "1" : "0" );
 }
 return sb.toString();
```

```
-1.0
1 0
3.0
010000000110000000000000000000000
                 3 5
0100000001110000000000000000000000
                 3 75
010000000111111111111111111111111111
                 3.9999998
6.0
256.0
00000000100000000000000000000000
                 1 17549435E-38
1100000001110000000000000000000000
                 -3.75
2.5521178E38
01111111100001001100000000000000000
                 1.8276885E38
01111111011111111111111111111111111
                 3.4028235E38
                 Infinity
-Infinity
NaN
NaN
```

### Addition von Gleitkommazahlen $y = a_1 + a_2$

- ▶ Skalierung des betragsmäßig kleineren Summanden
- ▶ Erhöhen des Exponenten, bis  $e_1 = e_2$  gilt
- ▶ gleichzeitig entsprechendes Skalieren der Mantisse ⇒ schieben
- ► Achtung: dabei verringert sich die effektive Genauigkeit des kleineren Summanden
- ▶ anschließend Addition/Subtraktion der Mantissen
- ▶ ggf. Normalisierung des Resultats
- ► Beispiele in den Übungen

Ziffern und Zahlen - Gleitkomma und II

$$a = 9,725 \cdot 10^7$$
  $b = 3,016 \cdot 10^6$ 

$$y = (a + b)$$
  
=  $(9,725 \cdot 10^7 + 0,3016 \cdot 10^7)$  Angleichung der Exponenten  
=  $(9,725 + 0,3016) \cdot 10^7$  Distributivgesetz  
=  $(10,0266) \cdot 10^7$  Addition der Mantissen  
=  $1,00266 \cdot 10^8$  Normalisierung

Distributivgesetz Addition der Mantissen Normalisierung

$$= 1.003 \cdot 10^8$$

Runden bei fester Stellenzahl

normalerweise nicht informationstreu!

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

#### Probleme bei Subtraktion zweier Gleitkommazahlen

#### Fall 1 Exponenten stark unterschiedlich

- kleinere Zahl wird soweit skaliert, dass von der Mantisse (fast) keine gültigen Bits übrigbleiben
- kleinere Zahl geht verloren, bzw. Ergebnis ist stark ungenau
- ► Beispiel: 1.0E20 + 3.14159 = 1.0E20

#### Fall 2 Exponenten gleich, Mantissen fast gleich

- ▶ fast alle Bits der Mantisse löschen sich aus
- ▶ Resultat hat nur noch wenige Bits effektiver Genauigkeit

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen

#### Multiplikation von Gleitkommazahlen $y = a_1 \cdot a_2$

- Multiplikation der Mantissen und Vorzeichen
  - Anmerkung: Vorzeichen  $s_i$  ist hier  $-1^{sBit}$  Berechnung als  $sBit = sBit_1$  XOR  $sBit_2$
- ► Addition der Exponenten
- ggf. Normalisierung des Resultats

$$y = (s_1 \cdot s_2) \cdot (m_1 \cdot m_2) \cdot b^{e_1 + e_2}$$

#### Division entsprechend:

- Division der Mantissen und Vorzeichen
- ► Subtraktion der Exponenten
- ▶ ggf. Normalisierung des Resultats

$$y = (s_1/s_2) \cdot (m_1/m_2) \cdot b^{e_1-e_2}$$

- schnelle Verarbeitung großer Datenmengen
- ► Statusabfrage nach jeder einzelnen Operation unbequem
- ▶ trotzdem Hinweis auf aufgetretene Probleme wichtig
- $\Rightarrow$  Inf (infinity): spezieller Wert für plus/minus Unendlich Beispiele: 2/0, -3/0,  $arctan(\pi)$ , usw.
- $\Rightarrow$  NaN (not-a-number): spezieller Wert für ungültige Operation Beispiele:  $\sqrt{-1}$ , arcsin(2,0), Inf/Inf, usw.

# IEEE 754: Infinity Inf, Not-a-Number NaN, $\pm 0$ (cont.)

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen

normalisiert	V  0 < Exp < Max	jedes Bitmuster
denormalisiert	V 000	jedes Bitmuster $\neq$ 000
0	V 000	000
Inf	V 111	000
NaN	V 111	jedes Bitmuster ≠ 0 00

- Rechnen mit Inf funktioniert normal: 0/Inf = 0
- ▶ NaN für undefinierte Werte: sqrt(-1), arcsin(2.0), ...
- ▶ jede Operation mit NaN liefert wieder NaN

5.7 Ziffern und Zahlen - Gleitkomma und IEEE 754

64-040 Rechnerstrukturen

#### java FloatInfNaNDemo

```
0 / 0 = NaN
1 / 0 = Infinity
-1 / 0 = -Infinity
1 / Infinity = 0.0
Infinity + Infinity = Infinity
Infinity + -Infinity = NaN
Infinity * -Infinity = -Infinity
Infinity + NaN = NaN
sqrt(2) = 1.4142135623730951
sqrt(-1) = NaN
0 + NaN = NaN
NaN == NaN? = false
                                                Achtung
Infinity > NaN? = false
                                                Achtung
```

- die Differenz zwischen den beiden Gleitkommazahlen, die einer gegebenen Zahl am nächsten liegen
- ▶ diese beiden Werte unterscheiden sich im niederwertigsten Bit der Mantisse ⇒ Wertigkeit des LSB
- ▶ daher ein Maß für die erreichbare Genauigkeit
- ► IEEE 754 fordert eine Genauigkeit von 0,5 ULP für die elementaren Operationen: Addition, Subtraktion, Multiplikation, Division, Quadratwurzel
  - = der bestmögliche Wert
- ▶ gute Mathematik-Software garantiert  $\leq 1$  ULP auch für höhere Funktionen: Logarithmus, Sinus, Cosinus usw.
- ▶ Progr.sprachenunterstützung, z.B. java.lang.Math.ulp( double d )

- ▶ sorgfältige Behandlung von Rundungsfehlern essentiell
- ▶ teilweise Berechnung mit zusätzlichen Schutzstellen
- ▶ dadurch Genauigkeit ±1 ULP für alle Funktionen
- ziemlich komplexe Sache
- ▶ in dieser Vorlesung nicht weiter vertieft
- beim Einsatz von numerischen Algorithmen essenziell

- die meisten Rechner sind für eine Wortlänge optimiert
- ▶ 8-bit, 16-bit, 32-bit, 64-bit, . . . Maschinen
- die jeweils typische Länge eines Integerwertes
- und meistens auch von Speicheradressen
- zusätzlich Teile oder Vielfache der Wortlänge unterstützt
- ▶ 32-bit Rechner
  - ▶ Wortlänge für Integerwerte ist 32-bit
  - adressierbarer Speicher ist 2<sup>32</sup> Bytes (4 GiB)
  - bereits zu knapp für speicherhungrige Applikationen
- ▶ derzeit Übergang zu 64-bit Rechnern (PCs)
- kleinere Wortbreiten: embedded-Systeme (Steuerungsrechner), Mobilgeräte etc.

# Datentypen auf Maschinenebene

5.8 Ziffern und Zahlen - Maschinenworte

64-040 Rechnerstrukturen

- ▶ gängige Prozessoren unterstützen mehrere Datentypen
- entsprechend der elementaren Datentypen in C, Java, ...
- void\* ist ein Pointer (Referenz, Speicheradresse)
- ▶ Beispiel für die Anzahl der Bytes:

C Datentyp	DEC Alpha	typ. 32-bit	Intel IA-32 (x86)
int	4	4	4
long int	8	4	4
char	1	1//1	13
short	2	2	2
float	4	4	4
double	8	8	8
long double	8	8	10/12
void *	8	4	4

64-040 Rechnerstrukturen

5.8 Ziffern und Zahlen - Maschinenworte

### Abhängigkeiten (!)

- Prozessor
- Betriebssystem
- Compiler

www.agner.org/optimize/ calling\_conventions.pdf

segment word size		16 bit 32 bit			bit				64 bit				
compiler	Microsoft	Borland	Watcom	Microsoft	Intel Windows	Borland	Watcom	Gnu v.3.x	Intel Linux	Microsoft	Intel Windows	Gnu	Intel Linux
bool	2	1	1	1	1	1	1	1	1	1	1	1	1
char	1	1	1	1	1	1	1	1	1	1	1	1	1
wchar_t		2		2	2	2	2	2	2	2	2	4	4
short int	2	2	2	2	2	2	2	2	2	2	2	2	2
int	2	2	2	4	4	4	4	4	4	4	4	4	4
long int	4	4	4	4	4	4	4	4	4	4	4	8	8
int64				8	8			8	8	8	8	8	8
enum	2	2	1	4	4	4	4	4	4	4	4	4	4
float	4	4	4	4	4	4	4	4	4	4	4	4	4
double	8	8	8	8	8	8	8	8	8	8	8	8	8
long double	10	10	8	8	16	10	8	12	12	8	16	16	16
m64				8	8				8		8	8	8
m128				16	16	7			16	16	16	16	16
m256				1	32	1			32		32		32
pointer	2	2	2	4	4	4	4	4	4	8	8	8	8
far pointer	4	4	4	100	1/								
function pointer	2	2	2	4	4	4	4	4	4	8	8	8	8
data member pointer (min)	2	4	6	4	4	8	4	4	4	4	4	8	8
data member pointer (max)		4	6	12	12	8	12	4	4	12	12	8	8
member function pointer (min)	2	12	6	4	4	12	4	8	8	8	8	16	16
member function pointer (max)		12	6	16	16	12	16	8	8	24	24	16	16

Table 1 shows how many bytes of storage various objects use for different compilers.

- [BO15] R.E. Bryant, D.R. O'Hallaron:
   Computer systems A programmers perspective.
   3rd global ed., Pearson Education Ltd., 2015.
   ISBN 978-1-292-10176-7. csapp.cs.cmu.edu
- [TA14] A.S. Tanenbaum, T. Austin: Rechnerarchitektur Von der digitalen Logik zum Parallelrechner.
  6. Auflage, Pearson Deutschland GmbH, 2014.
  ISBN 978-3-86894-238-5
- [Ifr10] G. Ifrah: *Universalgeschichte der Zahlen*. Tolkemitt bei Zweitausendeins, 2010. ISBN 978-3-942048-31-6
- [Kor16] Laszlo Korte: TAMS Tools for eLearning.
  Uni Hamburg, FB Informatik, 2016, BSc Thesis. tams.
  informatik.uni-hamburg.de/research/software/tams-tools

- [Gol91] D. Goldberg: What every computer scientist should know about floating-point. in: ACM Computing Surveys 23 (1991), March, Nr. 1, S. 5-48. www.validlab.com/goldberg/paper.pdf
- [Knu08] D.E. Knuth: The Art of Computer Programming, Volume 4, Fascicle 0, Introduction to Combinatorial Algorithms and Boolean Functions. Addison-Wesley Professional, 2008. ISBN 978-0-321-53496-5
- [Knu09] D.E. Knuth: The Art of Computer Programming, Volume 4, Fascicle 1, Bitwise Tricks & Techniques; Binary Decision Diagrams. Addison-Wesley Professional, 2009. ISBN 978-0-321-58050-4

- [Hei05] K. von der Heide: Vorlesung: Technische Informatik 1 interaktives Skript. Universität Hamburg, FB Informatik, 2005. tams.informatik.uni-hamburg.de/lectures/2004ws/ vorlesung/t1 Float/Double-Demonstration: demoieee754
- [Omo94] A.R. Omondi: Computer Arithmetic Systems Algorithms, Architecture and Implementations. Prentice-Hall International, 1994. ISBN 0-13-334301-4
- [Kor01] I. Koren: Computer Arithmetic Algorithms. 2nd edition, CRC Press, 2001. ISBN 978-1-568-81160-4. www.ecs.umass.edu/ece/koren/arith
- [Spa76] O. Spaniol: *Arithmetik in Rechenanlagen*. B. G. Teubner, 1976. ISBN 3-519-02332-6